

Klasterovanje sekvenci hantavirusa korišćenjem nukleotidnih k-mera

O hantavirusima

Hantavirusi obuhvataju grupu jednolančanih RNK virusa iz familije *Hantaviridae*. Ova familija obuhvata više rodova, pri čemu svi poznati sojevi koji izazivaju bolesti kod ljudi pripadaju rodu *Orthohantavirus*. Bolesti se ne prenose sa čoveka na čoveka, već ih prenose glodari (miševi, pacovi i voluharice) koji nemaju simptome infekcije. Bolest se na čoveka prenosi udisanjem čestica koje su kontaminirane urinom, pljuvačkom ili fecesom zaraženih jedinki.

U ovom radu su ispitivane nukleotidne sekvence četiri reprezentativne vrste:

Orthohantavirus hantanense (Hantaan virus) koji je zastupljen u istočnoj Aziji.

Orthohantavirus dobravaense (Dobrava-Belgrade virus) zastupljen u jugoistočnoj i centralnoj Evropi, a posebno na Balkanskom poluostrvu.

Orthohantavirus puumalaense (Puumala virus) zastupljen u severnoj, zapadnoj i centralnoj Evropi.

Orthohantavirus sinnombreense (Sin Nombre virus) zastupljen u Severnoj Americi.

Genom hantavirusa je jednolančana RNK negativne polarnosti, ukupne dužine između 11.800 i 12.500 nukleotida. Karakterističan je po tome što je podeljen na tri segmenta:

L segment (veliki) kodira RNK-zavisnu polimerazu, enzim koji je zadužen za umnožavanje virusa u ćeliji domaćina.

M segment (srednji) sadži uputstvo za sintezu površinskih glikoproteina omotača koji su zaduženi za ulazak virusa u ćeliju domaćina.

S segment (mali) kodira nukleokapsidni protein koji oblaže i štiti virusnu RNK. On je u direktnoj interakciji sa imunološkim sistemom domaćina pa trpi jači evolutivni pritisak.

Cilj rada

Cilj ovog rada je utvrditi da li se primenom pristupa bez poravnanja (alignment-free) i tehnikama klasterovanja (nenadgledanog učenja) mogu izdvojiti biološki značajna grupisanja i relevantni k-mer biomarkeri.

U radu je analizirano na koji način se nukleotidne sekvence grupišu na osnovu genetskih segmenata S, M i L i na osnovu vrsta virusa: Hantaan (*Orthohantavirus hantanense*), Dobrava-Belgrade (*Orthohantavirus dobravaense*), Puumala (*Orthohantavirus puumalaense*) i Sin Nombre (*Orthohantavirus sinnombreense*) kao i koji su to k-meri koji ih primarno karakterišu.

Korišćeni podaci i preprocesiranje

U radu su korišćeni podaci o virusima preuzeti iz NCBI Virus baze podataka. Pre samog klasterovanja je izvršeno čišćenje podataka, iz razmatranja su uklonjene veštački dobijene nukleotidne sekvence (neverifikovani uzorci, patentni za vakcine, smeše veštački stvorenih instanci, rekombinovani geni i slično).

Takođe izvršena je standardizacija oznaka segmenata i imputirane su vrednosti segmenata gde su nedostajale


na osnovu naslova instanci.

Za svaku razmatranu veličinu k-mera $k \in \{3,4,5,6\}$ izvršena je analiza na dva skupa podataka: jedan koji čine isključivo kompletne nukleotidne sekvence (kardinalnosti $N = 427$) i drugi koji čine i parcijalne nukleotidne sekvence (kardinalnosti $N = 5179$). Isti algoritmi su pokrenuti za oba skupa kako bi se analizirao uticaj parcijalnih sekvenci. Radi ublažavanja dužinskog šuma iz skupa svih sekvenci su izbačene sekvence čija je dužina manja od 350 nukleotida.


Napomena: Iako su hantavirusi jednolančani RNK virusi čiji genom sadrži uracil (U), NCBI Virus baza sekvence skladišti u standardnom cDNA formatu sa četvoroslovnom azbukom $\{A,C,G,T\}$. U skladu sa tim, analiza k-mera sprovedena je korišćenjem simbola T umesto U. Takođe iako je prilikom preuzimanja podataka iz NCBI Virus baze bila selektovana opcija za isključivanje dvosmislenih karaktera (ambiguous characters = 0), u preuzetom skupu su se i dalje pojavile sekvence koje su sadržale takve karaktere pa su one identifikovane i odbačene iz dalje analize.

Na narednim slikama su redom prikazane distribucije dužina sekvenci po segmentima u skupu svih sekvenci (nakon filtriranja) i u skupu kompletnih sekvenci. Prva slika pokazuje heterogenost sekvenci, iako je prisutno izdvajanje očekivanih pikova, vidi se veliki broj kratkih segmenata.

Na skupu kompletnih sekvenci vide se tri izolovana, jasna pika koja odgovaraju biološkim dužinama hantavirusa: S segmenti dužine oko 1.700 nt, M segmenti dužine oko 3.600 nt i L segmenti dužine oko 6.500 nt.



Distribucija dužine kompletnih nukleotidnih sekvenci po segmentima



Raspodela sekvenci po vrstama i segmentima u skupu kompletnih sekvenci

Genomski segment/ Vrsta virusa	S	M	L	Ukupno
<i>Orthohantavirus dobravaense</i>	18	12	7	37
<i>Orthohantavirus hantanense</i>	91	72	86	249
<i>Orthohantavirus puumalaense</i>	53	39	31	123
<i>Orthohantavirus sinnombreense</i>	6	6	6	18
Ukupno	168	129	130	427

Raspodela sekvenci po vrstama i segmentima u skupu svih sekvenci

Genomski segment / Vrsta virusa	S	M	L	Ukupno
<i>Orthohantavirus dobravaense</i>	308	92	38	438
<i>Orthohantavirus hantanense</i>	648	598	421	1667
<i>Orthohantavirus puumalaense</i>	1764	684	380	2828
<i>Orthohantavirus sinnombreense</i>	95	109	42	246
Ukupno	2815	1483	881	5179

Prikazani podaci ukazuju na jasne razlike u strukturi dva posmatrana skupa:

Skup kompletnih sekvenci: Odlikuje se ravnomernijom zastupljenošću genomskih segmenata (S: 39.3%, M: 30.2%, L: 30.4%). Iako *O. hantanense* i *O. puumalaense* čine većinu uzoraka, kod *O. sinnombreense* postoji simetrična zastupljenost (po 6 sekvenci za svaki segment).

Skup svih sekvenci: Vrste *O. puumalaense* (54.6%) i *O. hantanense* (32.2%) čine gotovo 87% podataka. Pored toga, dominira S segment sa 54.4% (posebno izražen kod *O. dobravaense* sa preko 70% udela), dok je L segment najmanje zastupljen (17%).

Metodologija rada

U ovom radu sekvence su analizirane bez prethodnog poravnanja (*alignment-free*), tako što je svaka sekvenca predstavljena frekvencijom nukleotidnih k-mera.

Za svaku razmatranu dužinu k-mera (nezavisno za skup kompletnih i svih sekvenci) izvršeni su sledeći koraci:

1) Za svaku sekvencu su izdvojeni i prebrojani svi k-meri koji se u njoj pojavljuju i podeljeni su ukupnim brojem k-mera te sekvence kako bi se dobile relativne frekvencije, koje ne zavise od dužine sekvence, čime je omogućeno fer poredjenje sekvenci različitih dužina.

2) Primenjena je PCA redukcija tako da se zadrži najmanji broj komponenti koji je dovoljan za opisivanje 80 posto varijanse podataka. Na ovaj način je značajno redukovana dimenzionalnost problema i smanjen je šum, dok je vizuelizacija klastera izvršena u prostoru prve tri glavne komponente.

3) Nad redukovanim podacima su primenjena 3 algoritma: K-Means, aglomerativno hijerarhijsko klasterovanje i GMM (Gaussian Mixture Model). Tokom modelovanja testirane su različite vrednosti hiperparametara (npr. broj klastera), a optimalne konfiguracije birane su na osnovu silueta koeficijenta.

4) Izdvojeni klasteri su evaluirani pomoću silueta koeficijenta i Davies-Bouldin indeksa, nakon čega su formirani klasteri upoređeni sa stvarnim biološkim podacima (genetskim segmentima i vrstama virusa) i izdvojeni su značajni k-meri koji određuju klaster na osnovu njihovog Z-skora, koji meri njihovu povećanu učestalost u klasteru u odnosu na ceo skup.

Rezultati klasterovanja (izabrani hiperparametri i interne metrike)

k	Dataset	Features	PCA comps	KMeans k	KMeans Sil	KMeans DB	GMM k	GMM Sil	GMM DB	Agg k	Agg linkage	Agg Sil	Agg DB
3	Complete	64	9	7	0.5559	0.7669	4	0.5379	0.8741	7	complete	0.5641	0.6959
3	All	64	20	8	0.2388	1.4699	7	0.2252	1.6411	7	ward	0.2238	1.7797
4	Complete	256	23	8	0.4171	1.0587	8	0.4171	1.0587	8	ward	0.4362	1.1588
4	All	256	50	8	0.2033	1.8283	8	0.1834	1.8748	8	ward	0.1758	1.9611
5	Complete	1024	39	8	0.3668	1.4640	8	0.3558	1.4229	8	ward	0.3738	1.3392
5	All	1024	109	7	0.1569	1.9490	8	0.1215	1.9252	8	ward	0.1774	1.9097
6	Complete	4096	58	8	0.2798	1.8140	8	0.2802	1.8201	8	ward	0.2919	1.5292
6	All	4096	214	8	0.1242	2.2285	2	0.1540	1.6349	8	ward	0.1362	2.2663

Za sve k-mere, svi modeli postižu znatno bolje rezultate (viši silueta koeficijent i niži Davies-Bouldin indeks) na skupu kompletnih sekvenci. Pogoršanje metrika na skupu svih sekvenci je posledica šuma koji unose kratke parcijalne sekvence. Takođe, u slučaju skupa svih sekvenci potreban je znatno veći broj PCA komponenti da bi se objasnilo 80% varijanse podataka (u slučaju 6-mera skoro četiri puta više komponenti, što dovodi do razređivanja prostora i očekivano slabijeg razgraničenja klastera).

Primećen je trend sa porastom dužine analiziranih k-mera. Povećanjem k sa 3 na 6 eksponencijalno raste broj mogućih k-mera (samim tim i broj razmatranih atributa) sa 64 u slučaju trinukleotida na 4096 u slučaju heksanukleotida, što dovodi do prokletstva dimenzionalnosti koje kao posledicu ima pogoršanje metrika.

Iako na skupu kompletnih sekvenci aglomerativno klasterovanje blago nadmašuje K-Means, K-Means se u celom procesu analize najrobusnije ponašao.

Dok je na čistom skupu kompletnih sekvenci za $k=3$ aglomerativno klasterovanje sa kompletnim povezivanjem dalo odlične rezultate, na skupu svih sekvenci standardne metode povezivanja (single, complete, average) potpuno su zakazale. Usled izraženog efekta lančanja (*chaining effect*) i dužinskog šuma, aglomerativno klasterovanje bi odvojilo instance u samo dva klastera. Skoro sve instance bi se stopile u jedan klaster, dok bi samo mali broj instanci završio u drugom klasteru, što bi rezultovalo visokim silueta koeficijentom, ali takvi rezultati nemaju biološki značaj pa je algoritam ponovo izvršen sa ward povezivanjem, čime je ovaj problem prevaziđen.

Pri analizi nukleotidnih 6-mera, usled velikog broja PCA komponenti efekat lančanja na aglomerativnom algoritmu sa standardnim metodama povezivanja se javio i na skupu kompletnih sekvenci, zbog čega je Ward povezivanje bilo nužno. Takođe, prilikom analize 6-mera svih sekvenci GMM model gubi mogućnost izdvajanja klastera i trivijalno razdvaja podatke na dva klastera, pri čemu jedan čini većina instanci.

Iako su se interne metrike poboljšavale povećanjem broja klastera, gornja granica razmatranog broja klastera zadržana je na 8. Analizirani uzorak čine tri genomska segmenta i četiri različite vrste virusa. Analizom je primećeno da se sve instance L segmenta kod skupa kompletnih sekvenci (kao i velika većina kod skupa svih sekvenci) uobičajeno grupišu u jedan klaster, pa preostalih 7 klastera ostavlja dovoljno prostora za praćenje diferencijacije vrsta na M i S segmentima. Tek pri analizi 6-mera prvi put je primećeno cepanje instanci L segmenta na dva zasebna klastera na skupu kompletnih sekvenci. Dalje povećanje broja klastera iznad 8 moglo bi dovesti do veštačkog cepanja prirodnih grupacija, čime bi se narušila njihova biološka interpretabilnost.

Analiza sadržaja klastera na skupu kompletnih sekvenci

1) Analiza 3-mera

Primenom algoritama za klasterovanje uočava se jasna razlika u ponašanju tri genomska segmenta:

L i M segmenti: Kod sva tri primenjena modela (K-Means, aglomerativnog i GMM), L i M segmenti formiraju po jedan zaseban i potpuno homogen klaster, bez unutrašnjeg razdvajanja po vrstama. L segment (130 sekvenci) karakterišu motivi bogati adeninom i timinom (AAG, TAG, TTA), dok je M segment (129 sekvenci) definisan motivima GTG, TGT i ACA.

S segment: Za razliku od prethodna dva, S segment pokazuje izrazitu specijsku osetljivost. Kod K-Means ($k = 7$) i aglomerativnog modela ($k = 7$), sve instance S segmenta podeljene su u pet homogenih klastera koji u potpunosti razgraničavaju posmatrane vrste.

Razlike među modelima: Aglomerativni pristup daje gotovo identičnu strukturu kao K-Means, dok GMM daje četiri klastera, zadržavajući homogene L i M segmente.

Ključni 3-mer biomarkeri po klasterima (K-Means)

Klaster	Dominantni segment i vrsta	Ključni 3-meri	Raspon Z-skora
Klaster 0	L segment (100%), sve vrste	AAG, TAG	1.17 - 1.18
Klaster 1	M segment (100%), sve vrste	GTG, TGT	1.34 - 1.37
Klaster 2	S: <i>O. hantanense</i> (100%)	GCA, TCC	1.90 - 2.00
Klaster 3	S: <i>O. puumalaense</i> (100%)	ACT, ATG	1.73 - 1.79
Klaster 4	S: <i>O. dobravaense</i> (100%)	TCG, GAC	2.93 - 3.33
Klaster 5	S: <i>O. hantanense</i> (100%)	GGA, GGC	1.46 - 1.51
Klaster 6	S: <i>O. sinnombreense</i> (100%)	CGT, TCA	2.12 - 2.60

2) Analiza 4-mera

Primenom algoritama na prostoru tetranukleotida potvrđuju se zakonitosti primećene analizom trinukleotida.

L i M segmenti: L segment se ponovo u sva tri algoritma grupiše u jedan klaster. Za razliku od njega, M segment se po prvi put deli na dva (skoro čista) klastera. Kod K-Means i GMM modela formira se čist klaster sekvenci vrste *Orthohantavirus hantanense* i jedan mešoviti klaster.

S segment: Svi modeli zadržavaju potpunu specijsku diferencijaciju kroz pet homogenih klastera koji razgraničavaju posmatrane vrste.

Razlike među modelima: K-Means i GMM su izvršili potpuno istu podelu po klasterima. Kod aglomerativnog modela podela M segmenta oslikava filogenetsku srodnost: jedan klaster formiraju *O. hantanense* i *O. dobravaense* (motivi CACA i CATG), dok drugi čine *O. puumalaense* i *O. sinnombreense* (motivi TTGT i TTTG).

Ključni 4-mer biomarkeri po klasterima (K-Means)

Klaster	Dominantni segment i vrsta	Ključni 4-meri	Raspon Z-skora
Klaster 0	L segment, sve vrste	TAGA, TTAG	1.27 - 1.37
Klaster 1	S: <i>O. hantanense</i> (100%)	CGGC, TGCG	2.91 - 3.15
Klaster 2	M segment, <i>O. hantanense</i> (100%)	CCCC, TAAC	1.82 - 1.92

Klaster 3	S: <i>O. hantanense</i> (100%)	GGCA, CGTT	2.01 - 2.16
Klaster 4	M segment, mešovite vrste	GTGT, TTGT	1.24
Klaster 5	S: <i>O. puumalaense</i> (100%)	CGCC, ATGC	1.84 - 1.93
Klaster 6	S: <i>O. dobravaense</i> (100%)	GACC, ACCT	2.90 - 2.98
Klaster 7	S: <i>O. hantanense</i> (100%)	TGGA, GGGT	2.18 - 2.25

3) Analiza 5-mera

U prostoru pentanukleotida primećuju se slični rezultati.

L segment: Kao i kod kraćih k-mera, sva tri algoritma izdvajaju L segment u jedan klaster.

M segment: Kod svih modela M segment je podeljen na dva klastera koji prate evolutivnu bliskost. Kod K-Means modela jedan klaster objedinjuje sekvence vrsta *O. hantanense* (85.7%) i *O. dobravaense* (14.3%), drugi klaster grupiše *O. puumalaense* (86.7%) i *O. sinnombreense* (13.3%). (potpuno isto kao i u slučaju 4-mera)

S segment: Dominantni S klasteri se ponovo raspoređuju u pet čistih klastera.

Razlike među modelima: Aglomerativni model formira dva čista M klastera (jedan sa svim vrstama, drugi isključivo sa instancama *O. hantanense*). GMM takođe izdvaja čist M klaster za *O. hantanense* (72 sekvence), dok drugi M klaster uključuje i manji udeo S sekvenci (S sekvence virusa *O. sinnombreense*) (57 M i 6 S instanci). Podela S segmenta na pojedinačne vrste ostaje dosledna kod svih modela.

Ključni 5-mer biomarkeri po klasterima (K-Means)

Klaster	Dominantni segment i vrsta	Ključni 5-meri	Raspon Z-skora
Klaster 0	S: <i>O. dobravaense</i> (100%)	GCCGC, TGACC	3.36 - 3.46
Klaster 1	S: <i>O. hantanense</i> (100%)	TGCGA, AGGGG	2.41 - 2.52
Klaster 2	L segment, mešovite vrste	TAGAG, GTTAG	1.12 - 1.13
Klaster 3	M: <i>O. hantanense</i> (85.7%) i <i>O. dobravaense</i> (14.3%)	CCCCA, GTGCC	1.53 - 1.55
Klaster 4	M: <i>O. puumalaense</i> (86.7%) i <i>O. sinnombreense</i> (13.3%)	AAAAA, CTTGT	1.76 - 1.79
Klaster 5	S: <i>O. puumalaense</i> (100%)	CGCGT, ACGCG	4.39 - 4.73

Klaster 6	S: <i>O. puumalaense</i> (100%)	CCGCC, CCCGC	2.34 - 2.41
Klaster 7	S: <i>O. hantanense</i> (100%)	TATGG, GACAG	1.92 - 1.96

4) Analiza 6-mera

Glavna razlika u odnosu na kraće k-mere ogleda se u **podeli skupa L sekvenci na dva klastera** u sva tri algoritma, što predstavlja prvu unutar-segmentnu podelu L segmenata na skupu kompletnih sekvenci.

Ključni 6-mer biomarkeri po klasterima (K-Means)

Klaster	Dominantni segment i vrsta	Ključni 6-meri	Raspon Z-skora
Klaster 0	L segment, <i>O. hantanense</i> (100.0%)	TCACGT, GTCACG	1.95 - 2.08
Klaster 1	S segment, <i>O. puumalaense</i> (100.0%)	CGCCAT, TGACGT	2.38 - 2.41
Klaster 2	S segment, <i>O. hantanense</i> (100.0%)	GCTGCG, CTTGGG	2.18 - 2.21
Klaster 3	M segment, <i>O. hantanense</i> (100.0%)	CCCCCA, GGTCGT	1.78 - 1.89
Klaster 4	S segment, <i>O. hantanense</i> (100.0%)	CATACG, TACGTC	2.63 - 2.73
Klaster 5	M segment, mešovite vrste	GATACC, AAAAAA	1.72 - 1.77
Klaster 6	S segment, <i>O. dobravaense</i> (100.0%)	AGCCGC, GCCGCT	3.85 - 4.14
Klaster 7	L segment, mešovite vrste	TGATGC, ATGTTT	1.39 - 1.47

Analiza sadržaja klastera na skupu svih sekvenci

1) Analiza 3-mera

Uvođenjem parcijalnih sekvenci i dužinskog šuma dolazi do pada unutrašnjih metrika, ali algoritmi i dalje uspevaju da izdvoje dominantne biološke signale.

L i M segmenti: Većina instanci L segmenta ostaje koncentrisana u jednom klasteru (motivi TTA i ATA), uz manji procenat rasutih po drugim klasterima. M segmenti se dele za razliku od klasterovanja na skupu kompletnih sekvenci (pri čemu je i dalje većina instanci u jednom klasteru), na jedan mešoviti klaster, a formiraju se i izrazito čisti specijski klasteri za *Orthohantavirus hantanense* i *Orthohantavirus puumalaense* sa povišenim vrednostima Z-skora.

S segment: Iako je čistoća klastera niža u poređenju sa skupom kompletnih sekvenci, S segment i dalje zadržava vodeću ulogu u razdvajanju vrsta.

Razlike među modelima: Aglomerativno klasterovanje (sa Ward povezivanjem) i GMM iako pronalaze klaster manje, imaju solidno preklapanje sa K-Means klasterovanjem, pri čemu sva tri modela zadržavaju jedan dominantan klaster za L segment i sličnu raspodelu specijskih podgrupa na S i M segmentima.

Ključni 3-mer biomarkeri po klasterima (K-Means)

Klaster	Dominantni segment i vrsta	Ključni 3-meri	Raspon Z-skora
Klaster 0	S segment, <i>O. dobravaense</i> (84.0%)	TCG, ACC	1.74 - 1.93
Klaster 1	S segment, <i>O. puumalaense</i> (99.5%)	ATG, CCC	0.85 - 0.97
Klaster 2	S segment, <i>O. hantanense</i> (93.1%)	GGG, GCA	1.36 - 1.45
Klaster 3	M segment, <i>O. puumalaense</i> (95.7%)	GTA, TTG	2.03 - 2.32
Klaster 4	M segment, <i>O. hantanense</i> (100%)	CAC, ACA	2.62 - 2.91
Klaster 5	M segment, mešovite vrste	TCT, TGT	0.83 - 0.96
Klaster 6	M segment, <i>O. puumalaense</i> (100%)	TGT, TGA	1.91 - 2.14
Klaster 7	L segment, mešovite vrste	TTA, ATA	1.00 - 1.22

2) Analiza 4-mera

U prostoru tetranukleotida na skupu svih sekvenci potvrđuju se zakonitosti uočene kod 3-mera, uz dodatno izoštravanje specijskih biomarkera kod S i M segmenata.

L i M segmenti: L segment dosledno ostaje koncentrisan u jednom dominantnom klasteru kod sva tri algoritma (K-Means 878/881, aglomerativni 880/881, GMM 879/881). Aglomerativni model izdvaja skoro skroz čist segmentni klaster (880 L sekvenci i samo jedna M sekvenca), dok K-Means pripaja i manji broj sekvenci ostalih segmenata (8 instanci M i 58 instanci S segmenta). M segment se većinski grupiše u jedan dominantan klaster, ali se pored njega javlja i potpuno homogen klaster M segmenta specifičan za vrstu *Orthohantavirus puumalaense* sa povišenim vrednostima Z-skora za motive AATG i TGTC ($Z = 2.50 - 3.12$).

S segment: Kao i na skupu kompletnih sekvenci, S segment najefikasnije razdvaja posmatrane vrste virusa.

Razlike među modelima: Aglomerativni model sa Ward povezivanjem pokazuje najveću otpornost na dužinski šum formirajući najčistije segmentne celine. Nasuprot tome, GMM pokazuje tendenciju spajanja većine M segmenata (1067) sa L segmentima u jedan obiman klaster, dok K-Means uspešno balansira između segmentne i specijske separacije.

Ključni 4-mer biomarkeri po klasterima (K-Means)

Klaster	Dominantni segment i vrsta	Ključni 4-meri	Raspon Z-skora
Klaster 0	S: <i>O. puumalaense</i> (100%)	AACC, ACGC	2.10 - 2.29

Klaster 1	M segment, mešovite vrste	CACA, GTGT	0.99 - 1.01
Klaster 2	S: <i>O. hantanense</i> (89.1%)	GGCA, GAGC	1.31 - 1.60
Klaster 3	S: <i>O. puumalaense</i> (100%)	GGCT, CTGA	2.98 - 3.01
Klaster 4	L segment, mešovite vrste	TAGA, TTAG	1.19 - 1.32
Klaster 5	M: <i>O. puumalaense</i> (100%)	AATG, TGTC	2.50 - 3.12
Klaster 6	S: <i>O. dobravaense</i> (100%)	CGTG, AAGG	2.28 - 2.66
Klaster 7	S: <i>O. puumalaense</i> (99.8%)	CCCG, CCAG	0.87 - 0.95

3) Analiza 5-mera

U prostoru pentanukleotida na skupu svih sekvenci dolazi do formiranja jednog velikog klastera, ali i do pojave izrazito specifičnih klastera sa ekstremno visokim vrednostima Z-skora.

L i M segmenti: Zbog uticaja dužinskog šuma i preklapanja motiva, svih 881 L sekvenci grupisano je u veliki klaster (N = 2227) zajedno sa većinom M sekvenci (1265) i manjim brojem kratkih S sekvenci (81). Usled velike heterogenosti i veličine ovog klastera, motivi beleže niske vrednosti Z-skora. Sa druge strane, M segment se uspešno cepa na dva potpuno homogena specijska klastera: Klaster 4 koji čine 84 M sekvence vrste *Orthohantavirus hantanense* (100%) uz izuzetno izražen CpG motiv ACCGC (Z = 5.04), i Klaster 6 sa 133 M sekvence specifične za *Orthohantavirus puumalaense* (100%) sa vodećim motivom TCTCT (Z = 4.20).

S segment: Kao i kod kraćih oligonukleotida, klasteri sa S segmentima pokazuju najveću otpornost na šum i dosledno razdvajaju vrste virusa.

Razlike među modelima: Aglomerativni model (Ward, k = 8) i GMM (k = 8) postižu visoku saglasnost sa K-Means podelom.

Ključni 5-mer biomarkeri po klasterima (K-Means)

Klaster	Dominantni segment i vrsta	Ključni 5-meri	Raspon Z-skora
Klaster 0	L (100% L sekvenci) + mešoviti M/S	AAAGT, TAAAT	0.67 - 0.75
Klaster 1	S: <i>O. dobravaense</i> (100%)	CGTGC, TCGTG	2.94 - 2.95
Klaster 2	S: <i>O. puumalaense</i> (100%)	CCTAC, CGTAA	1.96 - 2.14
Klaster 3	S: <i>O. puumalaense</i> (97.9%)	ACTTC, GGTAT	1.06 - 1.08
Klaster 4	M: <i>O. hantanense</i> (100%)	ACCGC, CGTCT	4.89 - 5.04
Klaster 5	S: <i>O. hantanense</i> (95.3%)	CGTTG, GGTGG	1.63 - 1.67

Klaster 6	M: <i>O. puumalaense</i> (100%)	TCTCT, CTAGG	3.77 - 4.20
------------------	------------------------------------	--------------	-------------

4) Analiza 6-mera

U prostoru heksanukleotida na skupu svih sekvenci postiže se najviša rezolucija unutar-segmentne podele, pri čemu specifični klasteri dostižu rekordne vrednosti Z-skora.

L i M segmenti: Kao i kod 5-mera, formira se jedan obiman klaster (N = 2312) u kome je smeštena većina M sekvenci (1365), L sekvenci (779) i manji broj S sekvenci (168), uz očekivano niske vrednosti Z-skora.

Međutim, prostor 6-mera omogućava da se i kod L i kod M segmenta odvoje homogeni podklasteri vrsta:

Kod L segmenta izdvaja se čist klaster sa 102 sekvence vrste *Orthohantavirus puumalaense*, definisan motivom GTAGTG sa izrazito visokim skorom (Z = 6.36).

Kod M segmenta obrazuje se čist klaster sa 117 sekvenci vrste *O. puumalaense*, okarakterisan motivom GGCGGA (Z = 5.73).

S segment: S segment ponovo demonstrira najbolje odvajanje vrsta virusa.

Ključni 6-mer biomarkeri po klasterima (K-Means)

Klaster	Dominantni segment i vrsta	Ključni 6-meri	Raspon Z-skora
Klaster 0	S segment, <i>O. puumalaense</i> (100.0%)	CACGTG, ACGTGG	1.11 - 1.12
Klaster 1	Uglavnom M i L segmenti, mešovite vrste	ATGATG, TGTTTT	0.61 - 0.65
Klaster 2	S segment, <i>O. hantanense</i> (100.0%)	CCGTTG, CGTTGT	1.91 - 2.09
Klaster 3	L segment, <i>O. puumalaense</i> (100.0%)	GTAGTG, TTACGT	5.41 - 6.36
Klaster 4	S segment, <i>O. puumalaense</i> (100.0%)	ACGCAT, CGCATA	6.26 - 6.50
Klaster 5	S segment, <i>O. puumalaense</i> (100.0%)	CTTTCG, AACGCC	3.16 - 3.22
Klaster 6	M segment, <i>O. puumalaense</i> (100.0%)	GGCGGA, GCGGAC	5.53 - 5.73
Klaster 7	S segment, <i>O. dobravaense</i> (100.0%)	GAGCGC, AGCGCT	3.73 - 3.77

Napomena: Visoke vrednosti Z-skora kod manje brojnih klastera (posebno kod analize 5-mera i 6-mera na skupu svih sekvenci) treba uzeti sa rezervom, jer to može biti posledica isključivo malog broja instanci u klasteru, a ne samog biološkog značaja k-mera.

Zaključak

Klasterovanje k-mera, uprkos slabim internim metrikama, uspešno prepoznaje strukturu hantavirusa na nivou segmenata i na nivou vrsta. S segment nosi najjači specijski signal i u svim eksperimentima demonstrira izuzetnu čistoću u razdvajanju posmatranih vrsta virusa. L i M segmenti pokazuju veću sličnost, te ih klasterovanje na prostoru 3-mera drži spojenim u po jednom klasteru. L segment je međusobno najbliži kod različitih vrsta i unutar sebe se deli tek na prostoru 6-mera (kad je reč o skupu kompletnih sekvenci), dok M

segment počinje da se delimično deli već na prostoru 4-mera. Ovi rezultati su biološki opravdani s obzirom na to da je S segment u stalnoj interakciji sa imunološkim sistemom domaćina, pa trpi najveći evolutivni pritisak i samim tim se i najviše razlikuje od vrste do vrste. Značaj signala S segmenta je posebno izražen kod malobrojnih vrsta virusa, iako su i *Orthohantavirus dobravaense* i *Orthohantavirus sinnombreense* znatno slabije zastupljeni u skupu podataka, instance *Orthohantavirus dobravaense* grade svoje klastere zahvaljujući većem broju S sekvenci. Sa druge strane, *Orthohantavirus sinnombreense* koji ima nedovoljan broj S sekvenci biva pripojen velikim mešovitim klasterima (često sa M i L segmentima) i uspeva da formira samostalan klaster jedino u slučaju klasterovanja 3-mera kompletnih sekvenci.